

딥러닝 용어

인공신경망(ANN)

- 생물학적 뉴런에서 영감을 받아 만든 머신러닝 알고리즘. 딥러닝이라고도 함

텐서플로 (TensorFlow)

- 구글이 2015년 공개한 딥러닝 라이브러리. GPU를 사용하여 신경망 모델을 효율적으로 훈련

케라스 (Keras)

- 텐서플로의 고수준 API. 현재 텐서플로에 내장됨. TensorFlow ≡ Keras

밀집층 (Dense Layer)

- 모든 뉴런이 연결된 완전연결층(Fully Connected Layer). 출력층에는 분류 카테고리 수만큼의 뉴런 사용

활성화 함수 (Activation)

- 뉴런의 선형방정식 결과에 적용되어 출력을 만드는 함수 (sigmoid, softmax 등)

원-핫 인코딩

- 정수 값을 해당 위치만 1이고 나머지 0인 배열로 변환. sparse_categorical_crossentropy 사용 시 자동 적용

Fashion MNIST

- 70,000개의 28×28 grayscale 이미지, 10종류 패션 아이템

손실함수 (Loss)

- 모델의 예측값과 실제 정답 사이의 오차를 수치화하여, 모델이 개선해야 할 방향과 크기를 알려주는 지표

Sequential 클래스

- 신경망 모델을 만드는 클래스. 층을 리스트로 전달하거나 add()로 추가

compile()

- 훈련 전 손실함수(loss)와 측정 지표(metrics) 등을 지정하는 메서드

fit() / evaluate()

- fit(): 모델 훈련 (입력, 타겟, epochs). evaluate(): 모델 성능 평가

심층신경망 (DNN)

- 2개 이상의 층을 포함한 신경망. 입력-출력 사이에 은닉층(Hidden Layer) 추가

ReLU 함수

- max(0, x). 시그모이드의 양 끝 포화 문제를 해결하며 계산이 간단

Flatten 층

- 다차원 입력을 1차원으로 펼치는 층. reshape() 대신 사용

옵티마이저 (Optimizer)

- 가중치와 절편을 학습하기 위한 알고리즘. 기본값은 RMSprop

SGD

- 확률적 경사 하강법. learning_rate(기본 0.01), momentum(보통 0.9 이상), nesterov 옵션

Adagrad

- 그래디언트 제곱을 누적하여 학습률로 나눔. learning_rate 기본 0.001

RMSprop

- Adagrad에 지수 감소를 적용하여 최근 그래디언트 강조. 케라스 기본 옵티마이저

Adam

- 모멘텀 최적화 + RMSprop 결합. 대체로 가장 좋은 성능. learning_rate 기본 0.001

하이퍼파라미터

- 사람이 지정하는 파라미터: 은닉층 수, 뉴런 수, 활성화함수, 배치 크기, 에포크 수, 옵티마이저 등

적응적 학습률

- 최적점에 가까워질수록 학습률을 낮춤. Adagrad, RMSprop, Adam이 해당

손실곡선 (Loss Curve)

- 에포크 증가에 따른 손실 변화. 훈련손실은 계속 감소, 검증손실은 어느 순간 증가 → 과대적합

History 객체

- fit()이 반환. history 디렉터리에 'loss', 'accuracy', 'val_loss', 'val_accuracy' 키로 값 저장

드롭아웃 (Dropout)

- 훈련 중 일부 뉴런 출력을 0으로 만들어 과대적합 방지. 앙상블 효과. 평가/예측 시 미적용

콜백 (Callback)

- 훈련 중간에 작업을 수행하는 객체. fit()의 callbacks 매개변수에 리스트로 전달

ModelCheckpoint

- 에포크마다 모델 저장. save_best_only=True로 최적 모델만 저장

EarlyStopping (조기종료)

- 검증손실 미향상 시 훈련 중지. patience로 참을 에포크 수 지정. restore_best_weights=True

모델 저장/복원

- save_weights(): 가중치만 / save(): 구조+가중치 / load_model(): 복원. HDF5(.h5) 포맷

합성곱 (Convolution)

- 입력의 일부에 필터(커널)의 가중치를 곱하고 절편을 더하는 연산

필터/커널 (Filter/Kernel)

- 합성곱에서 사용하는 가중치 행렬. 일반적으로 (3,3) 또는 (5,5). 필터 수 = 특성맵 수

특성맵 (Feature Map)

- 합성곱 계산의 출력 배열. 필터 하나가 하나의 특성맵을 만들

세임 패딩 (Same Padding)

- 출력 크기를 입력 크기와 동일하게 유지한다.

밸리드 패딩 (Valid Padding)

- 패딩 없이 합성곱. 출력 크기가 줄어듦. 기본값 padding='valid'

스트라이드 (Stride)

- 커널의 이동 크기. 기본값 1

최대 풀링 (Max Pooling)

- CNN(합성곱 신경망)에서 피쳐 맵의 공간적 크기(가로, 세로)를 줄이는 다운샘플링 기법

평균 풀링 (Average Pooling)

- CNN(합성곱 신경망)에서 피쳐 맵의 특정 영역 내 값들의 평균을 계산하여 다운샘플링하는 기법

CNN 구조 특징

- 너비·높이는 줄고, 깊이(채널)는 깊어짐. 마지막에 Flatten → Dense로 분류

Conv2D 클래스

- 2D 합성곱 연산. 매개변수: 필터 수, kernel_size, activation, padding, strides

MaxPooling2D 클래스

- 2D 최대 풀링. 첫 매개변수는 풀링 크기. strides 기본값은 풀링 크기와 동일

plot_model()

- 케라스 모델 구조를 그림으로 시각화. show_shapes=True로 입출력 크기 표시

CNN 파라미터 계산

- Conv2D: $\text{커널}W \times \text{커널}H \times \text{입력채널} \times \text{필터수} + \text{절편}$ / Dense: $\text{입력} \times \text{뉴런} + \text{절편}$

순차 데이터 (Sequential Data)

- 순서에 의미가 있는 데이터. 텍스트, 시계열 등

피드포워드 신경망

- 입력이 앞으로만 전달. 기억장치 없음. DNN, CNN이 해당

순환 신경망 (RNN)

- 이전 출력을 다음 입력에 재사용. 이전 데이터에 대한 '기억'을 가짐

셀 (Cell)

- 순환 신경망의 층. 여러 뉴런으로 구성되지만 하나의 셀로 표현

은닉 상태 (Hidden State)

- 셀의 출력. 다음 타임스텝에서 재사용. 마지막 은닉 상태만 다음 층으로 전달

타임스텝 (Timestep)

- 데이터를 처리하는 한 단계. 오래될수록 순환 정보가 희미해짐

tanh (하이퍼볼릭 탄젠트)

- 순환층의 기본 활성화 함수. 출력 범위 -1 ~ 1

RNN 파라미터 수

- $\text{입력} \times \text{뉴런} + \text{뉴런}^2 + \text{절편}$

순환층의 차원 축소

- 시퀀스(2D) → 마지막 타임스텝 출력(1D). Flatten 불필요

IMDB 리뷰 데이터셋

- 50,000개 영화 리뷰 (긍정/부정). 각 25,000개씩 훈련/테스트

토큰 (Token)

- 단어에 배정된 고유 코드. 0=패딩, 1=문장시작, 2=어휘사전 미등록

pad_sequences()

- 시퀀스 길이 통일. 짧으면 앞에 0 패딩, 길면 앞부분 자름

원-핫 인코딩 (in RNN)

- 토큰 값을 어휘사전 크기의 벡터로 변환 (해당 위치만 1)

단어 임베딩 (Word Embedding)

- 단어를 고정 크기의 실수 벡터로 변환. 훈련으로 의미있는 벡터 학습. 원-핫보다 차원 축소

SimpleRNN

- 기본 순환층 클래스. 첫 매개변수는 뉴런 수

Embedding 클래스

- 단어 임베딩 층. (어휘 크기, 임베딩 벡터 크기, input_length=시퀀스 길이)

LSTM (Long Short-Term Memory)

- 순환 상태 2가지: 은닉 상태 + 셀 상태(장기 기억). 작은 셀 4개

셀 상태 (Cell State)

- LSTM 내부에서만 순환하는 상태. 장기 기억 담당

GRU (Gated Recurrent Unit)

- 순환 상태 1가지(은닉 상태). 작은 셀 3개. LSTM보다 계산량 적지만 성능 유사

return_sequences

- True: 모든 타임스텝 출력 (순환층 쌓을 때 앞쪽 층에 필수). False(기본): 마지막만

순환층 드롭아웃

- LSTM/GRU의 dropout 매개변수로 비율 직접 지정

LSTM 파라미터

- (입력×뉴런 + 뉴런² + 절편) × 4

GRU 파라미터

- (입력×뉴런 + 뉴런² + 절편) × 3